

DELIVERY FAILURE LAB

Dokumentasi

Analisis Keandalan SLA Pengiriman dan Eksposur Finansial

Disusun oleh: **Lutfi Luthoifi**


Dataset: DataCo Supply Chain | Periode order: Jan 2015 - Jan 2018

Tools utama: Python / Pandas / SciPy / Excel / Tableau Public

TUJUAN DOKUMEN: Mencatat seluruh alur Delivery Failure Lab secara runtut, mulai dari pengambilan data, validasi grain dan KPI, analisis, persiapan data untuk Tableau, pembuatan calculated field dan parameter, sampai dashboard dipublikasikan dan presentasi disiapkan.

DELIVERY FAILURE LAB - END-TO-END PROJECT FLOW

From raw DataCo rows to an audited order-level reliability dashboard



Gambar 1. Alur kerja proyek dari data mentah sampai hasil akhir

Cara membaca dokumentasi

Dokumen ini mencatat proses pengerjaan Delivery Failure Lab dari awal sampai akhir. Fokusnya bukan hanya hasil akhir, tetapi juga keputusan penting yang dibuat selama analisis: cara menentukan grain data, membangun KPI, mengecek kualitas data, menyiapkan dataset untuk Tableau, dan menerjemahkan temuan menjadi rekomendasi yang masih bisa diuji.

- Bagian 1-4 membahas latar belakang, sumber data, grain data, dan pembentukan dataset level order.
- Bagian 5-10 membahas validasi SLA, kualitas data, pembuatan fitur, EDA, analisis shipping mode, severity, dan exposure.
- Bagian 11-15 membahas skenario perbaikan, dataset Tableau, calculated field, parameter, dan pembuatan worksheet.
- Bagian 16-20 membahas desain dashboard, interaksi filter, publishing, presentasi, serta rekomendasi lanjutan.
- Lampiran berisi data dictionary, referensi calculated field, skenario, struktur aset proyek, dan checklist QA.

ATURAN UTAMA: Semua KPI delivery dihitung pada level satu baris per Order Id. Order canceled dipisahkan dari denominator SLA. Financial exposure berarti nilai sales/profit yang terkait dengan late orders, bukan kerugian yang sudah terbukti terjadi.

1. Latar belakang dan tujuan

1.1 Titik awal proyek

Proyek ini dimulai dari dataset DataCo Supply Chain yang sebelumnya sudah pernah saya gunakan untuk analisis keterlambatan pengiriman. Pada versi ini saya membangun ulang analisisnya agar definisi KPI, grain data, istilah bisnis, dan skenario perbaikannya konsisten dari Python sampai Tableau dan presentasi.

1.2 Pertanyaan bisnis

Analisis diarahkan untuk menjawab empat hal: seberapa besar masalah keterlambatan yang tercatat, shipping mode mana yang perlu diperiksa lebih dulu, bagaimana membedakan masalah persentase dari masalah volume/exposure, dan seperti apa target perbaikan yang bisa dihitung tanpa menganggap hubungan yang terlihat sebagai bukti sebab-akibat.

1.3 Prinsip yang saya pakai selama analisis

- KPI baru dihitung setelah grain data dan denominator-nya jelas.
- Hubungan yang terlihat pada data saya perlakukan sebagai asosiasi, bukan langsung sebagai akar penyebab.
- Late rate yang tinggi tidak selalu berarti dampak bisnis terbesar; volume order tetap perlu dilihat.
- Nilai transaksi pada late orders saya sebut exposure, bukan kerugian yang sudah terjadi.
- Simulator dipakai sebagai skenario perencanaan, bukan prediksi hasil operasional.

2. Pengambilan data dan struktur

2.1 Sumber data dan salinan data mentah

Dataset diambil dari worksheet Google Sheets bernama DataCoSupplyChainDataset lalu dimuat ke Pandas. Setelah berhasil dibaca, saya langsung menyimpan salinan data mentah sebagai CSV. Tujuannya supaya sumber awal tetap terjaga dan proses selanjutnya dilakukan pada file kerja yang terkontrol.

```

worksheet = spreadsheet.worksheet("DataCoSupplyChainDataset")
data = worksheet.get_all_values()
df = pd.DataFrame(data[1:], columns=data[0])

RAW_PATH = PROJECT_PATH / "data" / "raw" / "DataCoSupplyChainDataset.csv"
df.to_csv(RAW_PATH, index=False)

```

Metrik	Nilai	Interpretasi
Baris data mentah	180,519	Satu baris data mentah mewakili satu order item, bukan satu order.
Kolom data mentah	53	Dataset memuat field customer, product, order, financial, dan shipping dalam satu tabel.
Order Item Id unik	180,519	Setiap baris memiliki Order Item Id yang unik.
Order Id unik	65,752	Satu Order Id dapat muncul pada beberapa baris item.

2.2 Pemilihan kolom yang digunakan

Dataset mentah berisi beberapa field yang tidak diperlukan untuk analisis delivery, termasuk informasi identitas pelanggan. Kolom seperti Customer Email dan Customer Password tidak dibawa ke dataset hasil proses maupun dashboard. File untuk Tableau hanya memuat atribut yang memang diperlukan untuk analisis pengiriman, market, customer segment, komposisi order, dan nilai finansial.

3. Menentukan grain data

3.1 Kenapa grain dicek sebelum menghitung KPI

Data mentah berisi 180,519 baris, tetapi satu order bisa muncul sampai lima kali karena setiap baris mewakili item di dalam order. Kalau baris mentah langsung dipakai sebagai denominator, order dengan banyak item akan mendapat bobot lebih besar. Karena itu semua KPI delivery harus dihitung pada level satu Order Id.

3.2 Bukti bahwa satu baris mewakili order item

Metrik	Nilai	Interpretasi
Perbandingan baris vs Order Item Id	180,519 = 180,519 unik	Mendukung kesimpulan bahwa satu baris data mentah adalah satu order line.
Perbandingan baris vs Order Id	180,519 vs 65,752	Satu Order Id dapat muncul antara 1 sampai 5 kali.
Order Item Id duplikat	0	Tidak ada duplikasi pada identifier order item.
Konsistensi atribut shipping dalam Order Id	0 order tidak konsisten	Shipping Mode, actual days, scheduled days, Delivery Status, dan late risk sama pada seluruh item dalam Order Id yang sama.

ALASAN: Atribut shipping konsisten di dalam satu Order Id, jadi nilainya cukup diambil satu kali per order. Quantity dan nilai finansial di level item tetap dijumlahkan. Dengan cara ini setiap order hanya mendapat satu bobot dalam KPI delivery.

4. Membentuk dataset level order

4.1 Menyiapkan tipe data

Sebelum agregasi, kolom numerik diubah dengan `pd.to_numeric` dan kolom tanggal dengan `pd.to_datetime`. Saya menggunakan `errors="coerce"` agar value yang tidak bisa dikonversi menjadi missing value dan bisa dicek, bukan tetap tersimpan sebagai string tanpa disadari.

```
numeric_columns = [
    "Days for shipping (real)", "Days for shipment (scheduled)",
    "Late_delivery_risk", "Order Item Discount",
    "Order Item Discount Rate", "Order Item Quantity",
    "Sales", "Order Item Total", "Order Profit Per Order"
]
for col in numeric_columns:
    df[col] = pd.to_numeric(df[col], errors="coerce")

df["order date (DateOrders)"] = pd.to_datetime(df["order date (DateOrders)"], errors="coerce")
df["shipping date (DateOrders)"] = pd.to_datetime(df["shipping date (DateOrders)"], errors="coerce")
```

4.2 Aturan agregasi

Setiap jenis kolom diperlakukan sesuai grain-nya. Atribut shipping yang konsisten di dalam satu Order Id cukup diambil satu kali, sedangkan quantity dan nilai finansial yang berada di level item dijumlahkan ke level order.

```
orders_df = (
    df.groupby("Order Id", as_index=False)
    .agg(
        Order_Date=("order date (DateOrders)", "first"),
        Shipping_Date=("shipping date (DateOrders)", "first"),
        Shipping_Mode=("Shipping Mode", "first"),
        Delivery_Status=("Delivery Status", "first"),
        Order_Status=("Order Status", "first"),
        Actual_Shipping_Days=("Days for shipping (real)", "first"),
        Scheduled_Shipping_Days=("Days for shipment (scheduled)", "first"),
        Market=("Market", "first"),
        Order_Region=("Order Region", "first"),
        Customer_Segment=("Customer Segment", "first"),
        Order_Line_Count=("Order Item Id", "count"),
        Total_Quantity=("Order Item Quantity", "sum"),
        Gross_Sales=("Sales", "sum"),
        Total_Discount=("Order Item Discount", "sum"),
        Net_Sales=("Order Item Total", "sum"),
        Order_Profit=("Order Profit Per Order", "sum")
    )
)
```

Metrik	Nilai	Interpretasi
Baris pada dataset level order	65,752	Sama dengan jumlah Order Id unik.
Order Id duplikat	0	Setelah agregasi, setiap Order Id hanya muncul satu kali.
Rekonsiliasi gross sales	\$36,784,735.01	Total sebelum dan sesudah agregasi tetap sama.
Rekonsiliasi profit	\$3,966,902.97	Total sebelum dan sesudah agregasi tetap sama.

4.3 Cara membaca kolom profit

Benefit per order dan Order Profit Per Order memiliki nilai yang sama pada seluruh baris mentah. Namun nilainya bisa berbeda antar-item di Order Id yang sama. Karena itu saya memperlakukannya sebagai profit di level item dan menjumlahkannya menjadi Order_Profit pada level order, bukan mengambil satu nilai pertama.

5. Memvalidasi SLA dan menentukan populasi analisis

5.1 Menghitung ulang selisih SLA

```
orders_df["SLA_Gap_Days"] = (
    orders_df["Actual_Shipping_Days"]
    - orders_df["Scheduled_Shipping_Days"]
)

orders_df["Calculated_Late_Flag"] = (orders_df["SLA_Gap_Days"] > 0).astype(int)
```

Aturannya sederhana: SLA_Gap_Days > 0 berarti late, = 0 berarti on time, dan < 0 berarti early.

5.2 Kenapa order canceled tidak masuk denominator SLA

Saat calculated late flag dibandingkan dengan Late_delivery_risk bawaan dataset, awalnya ada 1,650 perbedaan. Setelah dicek, semuanya berasal dari order dengan status Shipping canceled. Ketika order canceled dipisahkan, kedua flag cocok 100% pada 62,897 eligible delivered orders. Karena itu canceled order tetap dihitung untuk cancellation rate, tetapi tidak dipakai dalam late-rate denominator.

Metrik	Nilai	Interpretasi
Total Orders	65,752	Seluruh Order Id unik pada dataset level order.
Shipping canceled	2,855	Tetap dihitung untuk cancellation rate, tetapi tidak masuk denominator SLA.
Eligible Delivered Orders	62,897	Populasi yang digunakan untuk menghitung reliability delivery.
Late Orders	36,048	Eligible orders dengan SLA gap positif.
On Time	11,722	Eligible orders dengan SLA gap = 0.
Early	15,127	Eligible orders dengan SLA gap < 0.

ATURAN KPI: Late Delivery Rate = Late Orders / Eligible Delivered Orders. Order canceled tidak dimasukkan ke denominator karena belum menjadi observasi delivery SLA.

6. Pemeriksaan kualitas data

6.1 Missing value dan duplikasi

Saya mengecek ulang orders_df setelah agregasi untuk memastikan tidak ada Order Id ganda dan tidak ada missing value pada field yang digunakan untuk analisis. Dataset final untuk Tableau berisi 65,752 baris x 32 kolom dan tetap satu baris per order.

6.2 Validasi urutan dan perhitungan tanggal

Saya menghitung selisih waktu order ke shipping langsung dari timestamp. Tidak ada interval negatif atau nol. Namun jika dihitung sebagai durasi 24 jam penuh, hasilnya hanya cocok dengan Days for shipping (real) pada 94.57% order. Sebanyak 3,571 order berbeda tepat 0.5 hari.

Ketika timestamp dinormalisasi ke tanggal kalender sebelum dikurangkan, hasilnya cocok 100% dengan Actual_Shipping_Days. Jadi field Days for shipping (real) mengikuti pergantian tanggal kalender, bukan durasi jam yang presisi.

```
orders_df["Calendar_Shipping_Days"] = (
    orders_df["Shipping_Date"].dt.normalize()
    - orders_df["Order_Date"].dt.normalize()
).dt.days
```

Metrik	Nilai	Interpretasi
Rentang order date	2015-01-01 s.d. 2018-01-31	Tahun 2018 hanya mencakup sebagian periode.
Rentang shipping date	2015-01-03 s.d. 2018-02-06	Tanggal shipping dapat melewati akhir periode order.
Kecocokan durasi hari berdasarkan timestamp	94.57%	Durasi jam pada timestamp bukan dasar perhitungan field actual days.
Kecocokan berdasarkan tanggal kalender	100%	Digunakan sebagai dasar interpretasi field actual days.

CATATAN SAME DAY: Seluruh 3,407 eligible Same Day orders memiliki selisih timestamp 12 jam. Sebanyak 1,759 masih berada pada tanggal yang sama (actual days = 0), sedangkan 1,648 melewati pergantian tanggal (actual days = 1 dan tercatat late). Definisi cutoff layanan perlu divalidasi sebelum menilai performa Same Day secara operasional.

7. Pembuatan fitur untuk analisis

Setelah grain dan aturan SLA sudah aman, saya menambahkan field yang memang dibutuhkan untuk KPI dan analisis lanjutan. Fokusnya bukan menambah banyak kolom, tetapi membuat field yang jelas fungsinya untuk segmentasi, rekonsiliasi KPI, dan Tableau.

Calculated field	Formula	Tujuan
Order_Year / Month / Quarter	diturunkan dari Order_Date	Digunakan untuk filter waktu dan analisis tren.
SLA_Status	Canceled / Late / On Time / Early berdasarkan Delivery_Status dan SLA_Gap_Days	Label hasil SLA yang mudah dibaca dan saling terpisah.
Delay_Severity	Canceled / No Delay / 1 Day / 2 Days / 3+ Days	Membedakan jumlah kasus dari tingkat keparahan keterlambatan.
Order_Complexity	1 line = Single; 2-3 = Medium; 4-5 = High	Digunakan untuk mengecek apakah kompleksitas order berkaitan dengan late rate.
Is_Eligible	Delivery_Status != Shipping canceled	Flag untuk denominator.
Is_Late	SLA_Status == Late	Flag untuk numerator late order.
Is_On_Time / Is_Early / Is_Canceled	flag status	Dipakai untuk rekonsiliasi KPI.
Delay_Days	max(SLA_Gap_Days, 0)	Besarnya keterlambatan dalam hari.
Is_Loss_Order	Order_Profit < 0	Digunakan untuk perbandingan profit secara deskriptif.

7.1 Distribusi kompleksitas order

Metrik	Nilai	Interpretasi
1 line	19,850 order	Order dengan satu line item.
2 lines	11,447	Kompleksitas menengah.
3 lines	11,398	Kompleksitas menengah.
4 lines	11,704	Kompleksitas tinggi.
5 lines	11,353	Kompleksitas tinggi.

Metrik	Nilai	Interpretasi
Median	3 lines	Sebagian besar order memiliki lebih dari satu line item.

8. Baseline utama dan EDA

Metrik	Nilai	Interpretasi
Late Delivery Rate	57.31%	36,048 dari 62,897 eligible orders.
On-time / Early Rate	42.69%	26,849 dari 62,897 eligible orders.
Cancellation Rate	4.34%	2,855 dari 65,752 total orders.
Late Orders	36,048	Jumlah late order secara absolut.
Eligible Orders	62,897	Populasi yang digunakan untuk metrik reliability.

8.1 Pola keterlambatan dari waktu ke waktu

Late rate bulanan tidak hanya tinggi pada satu periode. Dalam 37 observasi bulanan, nilainya berada di kisaran 55.0%-59.9%. Titik terendah terjadi pada April 2017 (55.04%) dan tertinggi pada Juni 2016 (59.86%). Pola ini menunjukkan masalah yang berulang pada data historis, meskipun tidak bisa langsung dianggap akan sama pada kondisi operasional saat ini.

INTERPRETASI: Late rate yang tetap tinggi dari bulan ke bulan menunjukkan bahwa pola ini tidak berasal dari satu periode saja pada data historis. Namun pola historis tidak otomatis mewakili kondisi operasional saat ini. Januari 2018 juga hanya mencakup Pacific Asia, sehingga tidak bisa dibandingkan sebagai satu tahun penuh.

9. Analisis reliability berdasarkan Shipping Mode

Metrik	Nilai	Interpretasi
First Class	100.00% late	9,602 eligible; 9,602 late; SLA 1 hari; rata-rata actual 2.0 hari.
Second Class	79.99% late	12,256 eligible; 9,803 late; SLA 2 hari; rata-rata actual ~4.0 hari.
Same Day	48.37% late	3,407 eligible; 1,648 late; scheduled 0 hari kalender.
Standard Class	39.85% late	37,632 eligible; 14,995 late; SLA 4 hari; rata-rata actual ~4.0 hari.

Ada dua hal yang perlu dibaca bersama. First Class dan Second Class memiliki late rate paling tinggi, sedangkan Standard Class memiliki volume eligible dan jumlah late order terbesar. Artinya prioritas berdasarkan persentase dan prioritas berdasarkan skala tidak selalu sama.

9.1 Kenapa Shipping Mode menjadi sinyal paling kuat

Supaya tidak memilih driver hanya dari visual, saya mengukur kekuatan hubungan beberapa fitur kategorikal terhadap Is_Late menggunakan bias-corrected Cramer's V. Shipping Mode menghasilkan nilai paling tinggi dibanding fitur lain yang diuji.

Metrik	Nilai	Interpretasi
Shipping Mode	0.481	Asosiasi terkuat di antara fitur kategorikal yang diuji.
Order Region	0.012	Sangat lemah.
Order Year	0.001	Sangat lemah.

Metrik	Nilai	Interpretasi
Market	0.000	Nilai setelah koreksi bias dibulatkan menjadi nol.
Customer Segment	0.000	Tidak menunjukkan asosiasi yang berarti pada pengujian ini.
Order Complexity	0.000	Tidak menunjukkan asosiasi yang berarti pada pengujian ini.

CATATAN INTERPRETASI: Shipping Mode disebut sebagai asosiasi atau pembeda yang paling kuat pada fitur yang diuji, bukan sebagai akar penyebab. Dataset tidak memiliki detail carrier, kapasitas warehouse, staffing, antrean dispatch, timestamp pick-pack, atau kondisi route untuk membuktikan penyebab operasional.

10. Tingkat keterlambatan dan pemeriksaan profit

10.1 Tingkat keterlambatan

Metrik	Nilai	Interpretasi
Terlambat 1 hari	21,130 58.6%	Kelompok late order terbesar.
Terlambat 2 hari	10,010 27.8%	Kelompok terbesar kedua.
Terlambat 3+ hari	4,908 13.6%	Jumlah lebih kecil, tetapi tingkat keterlambatannya lebih berat.

Sebanyak 58.6% late orders terlambat tepat satu hari. Ini tidak berarti seluruhnya pasti mudah diperbaiki, tetapi kelompok ini cukup besar untuk dijadikan fokus pemeriksaan proses, terutama cutoff, waktu dispatch, dan kesesuaian janji layanan.

10.2 Pemeriksaan profit

Rata-rata profit yang tercatat pada late orders sekitar \$59.37, sedangkan rata-rata tertimbang kelompok non-late sekitar \$62.06. Selisihnya hanya sekitar \$2.70, dan loss-order rate ketiga kelompok juga hampir sama. Dari data ini belum ada dasar yang cukup untuk mengatakan bahwa keterlambatan menyebabkan penurunan profit.

11. Mengukur financial exposure

Saya menghitung net sales dan profit yang terkait dengan late orders untuk melihat besarnya nilai transaksi yang berada pada kelompok bermasalah. Angka ini membantu menentukan prioritas, tetapi tidak saya perlakukan sebagai kerugian yang terjadi akibat keterlambatan.

Metrik	Nilai	Interpretasi
Total late-order net sales exposure	\$18.08M	Net sales yang terkait dengan 36,048 late orders.
Profit tercatat pada late orders	\$2.14M	Profit yang tercatat pada late orders, bukan profit yang hilang.
Standard Class	\$7.52M 41.6%	Exposure terbesar karena volumenya paling besar.
Second Class	\$4.92M 27.2%	Late rate tinggi dengan volume yang masih besar.
First Class	\$4.86M 26.9%	Late rate tertinggi, tetapi skalanya lebih kecil dari Standard.
Same Day	\$0.79M ~4.4%	Exposure paling kecil.

PENAMAAN METRIK: Istilah "Profit at Risk" tidak digunakan. Dashboard memakai Late-Order Sales Exposure / Financial Exposure karena dataset tidak memiliki refund, claim, biaya logistik tambahan, kompensasi, churn, atau bukti causal lost profit.

12. Membangun skenario perbaikan

Simulator dibuat untuk menjawab pertanyaan perencanaan: jika jumlah late orders berkurang secara relatif sebesar X% dengan jumlah eligible orders tetap, berapa late orders yang tersisa, berapa projected late rate, dan berapa sales exposure yang berpindah keluar dari kategori late. Ini hanya skenario matematis, bukan model prediksi.

Metrik	Nilai	Interpretasi
Baseline late orders	36,048	Jumlah late order pada baseline historis.
Target perbaikan	10% relatif	Skenario default.
Late orders avoided	3,605	ROUND(36,048 x 10%).
Projected late orders	32,443	36,048 - 3,605.
Projected late rate	51.58%	32,443 / 62,897.
Exposure improvement	~\$1.81M	Perkiraan sales exposure yang berpindah keluar dari kategori late pada skenario.

CATATAN: Exposure improvement bukan tambahan revenue atau penghematan kas. Dampak ekonomi yang nyata baru bisa diukur jika tersedia data biaya/claim/refund yang relevan dan hasil pilot operasional.

13. Menyiapkan dataset untuk Tableau

Setelah model analisis selesai, saya mengekspor 32 field yang memang dibutuhkan dashboard. Grain tetap dijaga pada satu baris per Order Id, sehingga file final berisi 65,752 baris x 32 kolom.

```
tableau_columns = [
    "Order Id", "Order_Date", "Shipping_Date", "Order_Year", "Order_Month",
    "Order_Quarter", "Shipping_Mode", "Delivery_Status", "Order_Status",
    "Actual_Shipping_Days", "Scheduled_Shipping_Days", "SLA_Gap_Days",
    "SLA_Status", "Delay_Severity", "Delay_Days", "Market", "Order_Region",
    "Order_Country", "Customer_Segment", "Order_Line_Count", "Order_Complexity",
    "Total_Quantity", "Gross_Sales", "Total_Discount", "Net_Sales", "Order_Profit",
    "Is_Eligible", "Is_Late", "Is_On_Time", "Is_Early", "Is_Canceled", "Is_Loss_Order"
]
```

13.1 Kenapa CSV dikonversi ke Excel

Pada tahap awal Tableau sempat membaca beberapa field CSV dengan tipe yang tidak konsisten. Untuk mengurangi risiko kolom numerik atau tanggal terbaca sebagai string, file Tableau-ready juga dibuat dalam format Excel. Setelah dimuat, pengecekan pertama adalah memastikan jumlah baris tetap 65,752.

13.2 QA sebelum mulai membangun dashboard

1. Pastikan jumlah baris = 65,752.
2. Pastikan Order Id menjadi Dimension, bukan Measure yang dijumlahkan.
3. Pastikan Order_Date dan Shipping_Date terbaca sebagai date/datetime.
4. Pastikan Order_Year, Market, Order_Region, Shipping_Mode, dan Delay_Severity menjadi Dimension.
5. Pastikan Is_Eligible, Is_Late, Is_Canceled, Net_Sales, serta Actual/Scheduled Shipping Days terbaca sebagai Measure numerik.

6. Buat sheet validasi KPI baseline dan Shipping Mode sebelum mulai mendesain dashboard.

7. Lanjutkan ke desain hanya jika angka Tableau sudah sama dengan output Python.

14. Calculated field dan parameter di Tableau

Calculated field di bagian ini diambil dari workbook final. Untuk metrik yang memiliki denominator, saya menambahkan pengecekan denominator > 0 agar hasil tetap aman saat filter menghasilkan subset kosong.

Calculated field	Formula	Tujuan
Late Rate	IF SUM([Is_Eligible]) > 0 THEN SUM([Is_Late]) / SUM([Is_Eligible]) END	KPI utama untuk late rate SLA.
Cancellation Rate	IF COUNTD([Order Id]) > 0 THEN SUM([Is_Canceled]) / COUNTD([Order Id]) END	Order canceled dibagi seluruh order yang terpilih.
Eligible Orders	SUM([Is_Eligible])	Jumlah eligible orders untuk KPI card.
Late Orders	SUM([Is_Late])	Jumlah late orders untuk KPI card.
Promised SLA Label	IF [Shipping_Mode] = "Same Day" THEN "SAME DAY" ELSE STR(INT([Scheduled_Shipping_Days])) + " DAY SLA" END	Label SLA yang lebih mudah dibaca per shipping mode.
Reliability Severity	IF [Late Rate] >= 0.75 THEN "CRITICAL" ELSEIF [Late Rate] >= 0.45 THEN "HIGH" ELSE "ELEVATED" END	Klasifikasi warna untuk visual Shipping Mode Reliability.
Late Severity Share	IF TOTAL(SUM([Is_Late])) > 0 THEN SUM([Is_Late]) / TOTAL(SUM([Is_Late])) END	Persentase late orders pada setiap kategori severity.
Severity Track	1.0	Track latar 100% untuk desain bar-in-track.
Late Net Sales Exposure	IF [Is_Late] = 1 THEN [Net_Sales] ELSE 0 END	Net sales yang terkait dengan late orders.
Exposure Share	IF WINDOW_SUM(SUM([Late Net Sales Exposure])) > 0 THEN SUM([Late Net Sales Exposure]) / WINDOW_SUM(SUM([Late Net Sales Exposure])) END	Persentase exposure per shipping mode.
Late Orders Avoided	INT(ROUND(SUM([Is_Late]) * [Improvement Target], 0))	Jumlah late order yang diasumsikan berhasil dihindari pada skenario.
Projected Late Orders	SUM([Is_Late]) - [Late Orders Avoided]	Jumlah late order yang tersisa pada skenario.
Projected Late Rate	IF SUM([Is_Eligible]) > 0 THEN [Projected Late Orders] / SUM([Is_Eligible]) END	Late rate setelah skenario perbaikan.
Sales Exposure Improvement	IF SUM([Is_Late]) > 0 THEN SUM([Late Net Sales Exposure]) * [Late Orders Avoided] / SUM([Is_Late]) ELSE 0 END	Exposure yang berpindah keluar dari kategori late berdasarkan jumlah avoided yang sudah dibulatkan.
Projected Sales Exposure	SUM([Late Net Sales Exposure]) - [Sales Exposure Improvement]	Exposure yang masih berada pada kategori late setelah skenario.
Dashboard Year Filter	[YEAR] = "All Years" OR STR([Order_Year]) = [YEAR]	Filter tahun global yang dikendalikan parameter.
Dashboard Market Filter	[MARKET] = "All Markets" OR [Market] = [MARKET]	Filter market global yang dikendalikan parameter.
Dashboard Region Filter	[REGION] = "All Regions" OR [Order_Region] = [REGION]	Filter region global yang dikendalikan parameter.
Actual Days - Eligible	IF [Is_Eligible] = 1 THEN [Actual_Shipping_Days] END	Actual shipping days hanya untuk eligible orders; dipakai pada tooltip/rata-rata.
Scheduled Days - Eligible	IF [Is_Eligible] = 1 THEN [Scheduled_Shipping_Days] END	Scheduled shipping days hanya untuk eligible orders; dipakai pada tooltip/rata-rata.

14.1 Parameter

Metrik	Nilai	Interpretasi
Improvement Target	Float 0.00-0.25, kenaikan 0.05, default 0.10	Mengatur skenario.

Metrik	Nilai	Interpretasi
YEAR	List; default All Years	Parameter filter global.
MARKET	List; default All Markets	Parameter filter global.
REGION	List; default All Regions	Parameter filter global.

15. Pembuatan worksheet Tableau

Dashboard dibangun dari beberapa worksheet kecil dengan fungsi yang jelas, bukan satu worksheet besar. Cara ini membuat KPI, chart, filter, tooltip, dan simulator lebih mudah diatur serta lebih mudah diperbaiki ketika layout berubah.

Worksheet	Pembuatan	Fungsi
00 - Selection Status	Text mark	Pesan bantu ketika kombinasi filter tidak valid atau tidak menghasilkan data.
01 - Hero Late Rate	Text: Late Rate	KPI utama 57.31% dengan subtitle "Delivered orders missed their SLA".
01A - Late Orders KPI	Text: Late Orders	Kartu KPI 36,048.
01B - Eligible Orders KPI	Text: Eligible Orders	Kartu KPI 62,897.
01C - Cancellation KPI	Text: Cancellation Rate	Kartu KPI 4.34%.
02 - Shipping Mode Reliability	Rows: Shipping Mode + Promised SLA Label; Columns: Late Rate twice; dual-axis Bar + Circle	Chart lollipop untuk reliability, dengan label langsung, warna severity per mode, dan tooltip.
03 - Delay Severity	Rows: Delay Severity; Columns: MIN(Severity Track) + Late Severity Share; dual-axis Bar	Track abu-abu 100% di belakang bar berwarna; label menampilkan jumlah dan persentase.
04 - Monthly SLA Pulse	Columns: MONTH(Order Date); Rows: Late Rate (dual axis line/circle)	Tren bulanan dengan garis referensi baseline keseluruhan 57.31%.
05 - Net Sales Exposure	Rows: Shipping Mode; Columns: SUM(Late Net Sales Exposure)	Horizontal bar berdasarkan exposure; label menampilkan nilai dolar dan Exposure Share.
06 - Simulate The Fix	Text helper sheet	Worksheet bantu untuk logika simulator; bukan visual utama.
06A - Current Rate	Text: Late Rate	KPI current late rate pada simulator.
06B - Projected Rate	Text: Projected Late Rate	KPI projected late rate; ditampilkan dengan warna hijau.
06C - Current Orders	Text: Late Orders	Jumlah late orders saat ini.
06D - Projected Orders	Text: Projected Late Orders	Jumlah late orders setelah skenario.
06E - Orders Avoided	Text: Late Orders Avoided	Kartu dampak: jumlah order yang dihindari dari kategori late.
06F - Exposure Improvement	Text: Sales Exposure Improvement	Kartu dampak: perubahan sales exposure pada skenario.

16. Struktur dan desain dashboard

16.1 Susunan informasi pada dashboard

- Kiri atas: sinyal utama - late rate 57.31% serta KPI Late Orders, Eligible Orders, dan Cancellation Rate.
- Tengah atas: Shipping Mode Reliability untuk membandingkan late rate tiap mode.
- Kanan atas: Delay Severity dan Monthly SLA Pulse.


- Kiri bawah: Late-Order Sales Exposure untuk membandingkan rate dengan skala nilai transaksi.
- Kanan bawah: Simulate the Fix untuk melihat dampak skenario perbaikan.
- Header: filter Year / Market / Region. Footer: ringkasan insight dan catatan interpretasi.

16.2 Alasan pemilihan desain

- Ukuran dashboard dibuat 1600 x 900 agar nyaman untuk tampilan desktop dan portfolio.
- Tema gelap dipilih agar konsisten dengan konsep "Failure Lab" sekaligus menjaga fokus pada KPI dan chart.
- Merah/oranye digunakan untuk risiko, hijau terang untuk skenario perbaikan, dan off-white untuk teks netral.
- Label langsung lebih sering dipakai daripada legend supaya pembaca tidak perlu bolak-balik melihat keterangan warna.
- Map tidak ditambahkan karena geography bukan sinyal analitis terkuat pada hasil pengujian.
- Visual perbandingan menggunakan horizontal bar dan lollipop; pie/donut tidak dipakai untuk menghindari terlalu banyak chart dekoratif.
- Pesan "RATE != SCALE != EXPOSURE" dipakai untuk menegaskan bahwa persentase, volume, dan nilai transaksi perlu dibaca sebagai tiga hal yang berbeda.

16.3 Perubahan layout selama pengerjaan

Versi awal dashboard terlalu banyak memakai floating object sehingga alignment sulit dijaga. Layout kemudian disusun ulang memakai grid tetap dan KPI sheet yang bisa digunakan kembali. Simulator juga dipecah menjadi beberapa kartu agar current state, projected state, dan impact lebih mudah dibaca.



Gambar 2. Dashboard Delivery Failure Lab yang dipublikasikan

17. Filter, interaksi, dan QA dashboard

17.1 Filter global

YEAR, MARKET, dan REGION dibuat sebagai parameter yang dihubungkan ke calculated filter boolean. Setiap worksheet memakai filter boolean = True sehingga pilihan yang sama diterapkan ke seluruh bagian dashboard.

Dashboard Year Filter

[YEAR] = "All Years" OR STR([Order_Year]) = [YEAR]

Dashboard Market Filter

[MARKET] = "All Markets" OR [Market] = [MARKET]

Dashboard Region Filter

[REGION] = "All Regions" OR [Order_Region] = [REGION]

17.2 Penanganan hasil filter kosong

Workbook final memiliki Selected Order Count, Selected Eligible Count, dan Selection Status untuk memberi pesan ketika kombinasi filter tidak menghasilkan order atau hanya menghasilkan order canceled. Pengecekan denominator pada Late Rate dan Projected Late Rate juga mencegah pembagian dengan nol.

17.3 Interaksi simulator

Improvement Target menggunakan rentang 0%-25% dengan kenaikan 5% dan default 10%. Saat parameter berubah, Projected Late Orders, Projected Late Rate, Orders Avoided, Projected Exposure, dan Exposure Improvement ikut diperbarui.

18. Packaging dan publikasi Tableau

Untuk Tableau Public, datasource perlu tersedia sebagai extract yang bisa ikut dipaketkan. Workbook final disimpan sebagai TWBX agar source dan extract dapat dibawa bersama saat publish. Setelah dipublikasikan, saya mengecek versi browser untuk memastikan tidak ada label terpotong, overlap, worksheet hilang, atau parameter yang rusak.

Dashboard publik: Delivery Failure Lab - Tableau Public [Delivery Failure Lab - Tableau Public](#)

18.1 QA terakhir di browser

- Hero late rate tampil 57.31%.
- KPI 36,048 / 62,897 / 4.34% sama dengan baseline Python.
- Late rate tiap Shipping Mode sama dengan hasil validasi.
- Exposure per mode tampil sekitar \$7.52M / \$4.92M / \$4.86M / \$0.79M.
- Skenario default 10% menghasilkan 51.58%, 32,443, 3,605, dan sekitar \$1.81M.
- Filter Year / Market / Region berfungsi di Tableau Public.
- Catatan bahwa asosiasi bukan sebab-akibat dan skenario bukan hasil aktual tetap terlihat.

19. Presentasi dan komunikasi hasil

Dashboard digunakan untuk eksplorasi interaktif, sedangkan presentation deck merangkum cerita analisis untuk pembaca yang ingin memahami hasil secara cepat. Versi 2 menekankan koreksi grain, baseline SLA, perbedaan rate dan scale, severity, financial exposure, skenario 10%, serta rencana pilot yang masih berupa usulan.

19.1 Alur cerita untuk interview

1. Mulai dari masalah utama: 57.31% eligible delivered orders terlambat terhadap SLA.
2. Jelaskan koreksi grain: 180,519 item rows menjadi 65,752 unique orders.
3. Jelaskan denominator: order canceled tidak dianggap sebagai observasi delivery SLA.
4. Tunjukkan sinyal utama: First Class dan Second Class memiliki late rate paling tinggi.
5. Lanjutkan ke sisi skala: Standard Class memiliki jumlah late order dan sales exposure terbesar.
6. Tambahkan severity dan trend: mayoritas late orders terlambat satu hari dan late rate tetap tinggi dari bulan ke bulan.
7. Tegaskan batas interpretasi: asosiasi bukan bukti sebab-akibat dan exposure bukan kerugian aktual.
8. Tutup dengan skenario terukur: perbaikan relatif 10% = 3,605 late orders lebih sedikit dan projected late rate 51.58%.

20. Temuan utama dan langkah selanjutnya

- Late rate pada eligible orders adalah 57.31%, sehingga reliability menjadi masalah utama pada data historis.
- Shipping Mode memiliki asosiasi kategorikal paling kuat dengan Is_Late (Cramer's V sekitar 0.481).
- First Class dan Second Class perlu diperiksa dari sisi kelayakan SLA dan pelaksanaan layanan.
- Standard Class layak menjadi kandidat pilot proses karena membawa jumlah late order dan sales exposure terbesar.
- Keterlambatan satu hari membentuk 58.6% dari seluruh late orders dan menjadi segmen yang masuk akal untuk investigasi operasional.
- Target perbaikan relatif 10% bisa dipakai sebagai target perencanaan, tetapi hasilnya tetap perlu dibuktikan melalui pilot.
- Analisis lanjutan akan lebih kuat jika tersedia timestamp proses warehouse, data kapasitas, carrier/route, complaint/refund/claim, biaya, dan retention.

20.1 Usulan alur pilot 90 hari

Metrik	Nilai	Interpretasi
Hari 1-30	Validasi aturan SLA dan timestamp shipment	Operations + analyst; tetapkan baseline yang dapat dipercaya dan ruang lingkup pilot.
Hari 31-60	Uji perubahan pada SLA premium atau proses Standard Class	Logistics + warehouse; pantau reliability dan biaya.
Hari 61-90	Bandingkan pilot dengan kelompok pembanding yang sebanding	Analyst + finance; putuskan apakah pilot diperluas, direvisi, atau dihentikan.
Hari 91-180	Perluas hanya perubahan yang menunjukkan hasil konsisten	Operations lead; arahkan ke target penurunan relatif 10%.

Lampiran A. Data dictionary hasil proses

Field	Role/tipe di Tableau	Arti
Order Id	Dimension / integer	Kunci unik untuk satu order analitis.
Order_Date	Dimension / datetime	Timestamp order.
Shipping_Date	Dimension / datetime	Timestamp shipping.
Order_Year	Dimension / integer	Filter tahun.
Order_Month	Dimension / date	Tren bulanan.

Field	Role/tipe di Tableau	Arti
Order_Quarter	Dimension / string	Pengelompokan kuartal.
Shipping_Mode	Dimension / string	Jenis layanan pengiriman.
Delivery_Status	Dimension / string	Status delivery, termasuk canceled.
Order_Status	Dimension / string	Status order.
Actual_Shipping_Days	Measure / integer	Jumlah hari shipping berdasarkan tanggal kalender yang tercatat.
Scheduled_Shipping_Days	Measure / integer	Jumlah hari SLA yang dijanjikan.
SLA_Gap_Days	Measure / integer	Actual dikurangi scheduled.
SLA_Status	Dimension / string	Canceled / Late / On Time / Early.
Delay_Severity	Dimension / string	No Delay / 1 / 2 / 3+ / Canceled.
Delay_Days	Measure / integer	Bagian positif dari SLA gap.
Market	Dimension / string	Filter market.
Order_Region	Dimension / string	Filter region.
Order_Country	Dimension / string	Konteks negara.
Customer_Segment	Dimension / string	Analisis customer segment.
Order_Line_Count	Measure / integer	Jumlah baris item di dalam order.
Order_Complexity	Dimension / string	Single / Medium / High.
Total_Quantity	Measure / integer	Total quantity dari seluruh item.
Gross_Sales	Measure / real	Total Sales dari seluruh item.
Total_Discount	Measure / real	Total discount dari seluruh item.
Net_Sales	Measure / real	Total Order Item Total.
Order_Profit	Measure / real	Total profit line-level pada order.
Is_Eligible	Measure / 0-1	1 jika bukan Shipping canceled.
Is_Late	Measure / 0-1	1 jika SLA_Status = Late.
Is_On_Time	Measure / 0-1	1 jika SLA_Status = On Time.
Is_Early	Measure / 0-1	1 jika SLA_Status = Early.
Is_Canceled	Measure / 0-1	1 jika SLA_Status = Canceled.
Is_Loss_Order	Measure / 0-1	1 jika Order_Profit < 0.

Lampiran B. Referensi skenario 0%-25%

Metrik	Nilai	Interpretasi
0%	36,048 late tersisa 57.31% late rate	\$0.00M exposure improvement
5%	34,246 late tersisa 54.45% late rate	~\$0.90M exposure improvement
10%	32,443 late tersisa 51.58% late rate	~\$1.81M exposure improvement
15%	30,641 late tersisa 48.72% late rate	~\$2.71M exposure improvement
20%	28,838 late tersisa 45.85% late rate	~\$3.62M exposure improvement
25%	27,036 late tersisa 42.98% late rate	~\$4.52M exposure improvement

Lampiran C. Struktur aset proyek

Struktur folder proyek yang digunakan:

```

DEPP Delivery Project/
├── notebooks/
└── 01_data_quality_audit_COMPLETE.ipynb

```



```

├─ data/
│  └─ raw/
│     └─ DataCoSupplyChainDataset.csv
│  └─ processed/
│     ├── delivery_orders_tableau_ready.csv
│     └─ delivery_orders_tableau_ready.xlsx
├─ outputs/
│  ├── monthly_sla_trend.csv
│  ├── shipping_mode_summary.csv
│  ├── financial_exposure_by_mode.csv
│  ├── association_strength.csv
│  └─ improvement_scenarios.csv
├─ tableau/
│  └─ Delivery_Failure_Lab_FIXED_v2.twbx
├─ presentation/
│  └─ Delivery_Failure_Lab - Version 2 / Premium deck
└─ documentation/
   └─ Delivery_Failure_Lab_End_to_End_Project_Documentation.docx

```

Lampiran D. Checklist reproduksi dan QA akhir

- Data mentah berisi 180,519 baris dan 53 kolom.
- Jumlah unique Order Item Id = 180,519 dan duplicate Order Item Id = 0.
- Jumlah unique Order Id = 65,752 dan dataset level order juga tepat 65,752 baris.
- Atribut shipping konsisten di dalam setiap Order Id sebelum agregasi first digunakan.
- Total gross sales dan profit tetap sama sebelum dan sesudah agregasi ke level order.
- Jumlah canceled = 2,855 dan eligible = 62,897.
- Rekonsiliasi status: 36,048 Late + 11,722 On Time + 15,127 Early = 62,897 Eligible.
- Late rate = 57.31% dan cancellation rate = 4.34%.
- Calculated late flag cocok 100% dengan late flag dataset setelah order canceled dikeluarkan dari populasi SLA.
- Perbedaan tanggal kalender cocok 100% dengan Actual_Shipping_Days.
- Late rate per Shipping Mode = 100.00%, 79.99%, 48.37%, dan 39.85%.
- Cramer's V untuk Shipping Mode sekitar 0.481.
- Total late-order net sales exposure sekitar \$18.08M; Standard Class sekitar \$7.52M.
- Skenario 10% menghasilkan 3,605 avoided orders, 32,443 late orders tersisa, projected late rate 51.58%, dan exposure improvement sekitar \$1.81M.
- Tableau Public tampil tanpa worksheet rusak, label terpotong, atau error extract.
- Presentasi konsisten memakai bahasa "asosiasi, bukan sebab-akibat" dan "exposure, bukan kerugian aktual".

AKHIR DOKUMENTASI